

Definição do Problema de Dados e Seleção do Conjunto de Dados

Discentes:

Erika Vitoria Da Cruz Silva

Kelry Silva De Sousa

Victorya Lima Souza

Pedro Rusvel Pinheiro Siqueira De Carvalho

Docente: Prof. Alex Rogaleski Marques

Disciplina: Big Data e Ciência de Dados

Balsas – MA

2026

1. PROBLEMA

O Instituto Lírios atua no atendimento materno-infantil e em outros serviços de cuidados em saúde. Atualmente, a instituição não possui um sistema próprio para concentrar e organizar suas informações. A responsável utiliza ferramentas separadas, como WhatsApp, documentos do Word, pastas e Google Agenda, para registrar e consultar dados das clientes, atendimentos, contratos, agendamentos e pendências.

Os agendamentos são controlados pelo Google Agenda, enquanto os lembretes das consultas são enviados manualmente. As informações das clientes e os registros de atendimentos ficam distribuídos entre documentos e pastas. Já o controle de contratos e pendências é feito com etiquetas no WhatsApp, como “contrato assinado” e “pendência de assinatura”.

Essa forma de organização dificulta o gerenciamento das atividades, pois a responsável precisa consultar diferentes ferramentas para obter informações sobre uma mesma cliente. Além disso, o processo manual pode aumentar o tempo gasto na rotina da instituição e causar esquecimentos, atrasos no envio de lembretes ou dificuldade para localizar informações importantes do histórico de atendimento.

Portanto, o problema identificado está relacionado à ausência de um sistema centralizado para organizar os dados das clientes e apoiar o acompanhamento dos atendimentos realizados pelo Instituto Lírios.

2. SOLUÇÃO / MVP

A solução proposta é o desenvolvimento de um sistema web de gestão para o Instituto Lírios. O sistema deverá centralizar informações de clientes, serviços, agendamentos, contratos, pendências e históricos de atendimentos em um único ambiente.

O MVP, ou Produto Mínimo Viável, será a primeira versão funcional do sistema. Ele terá como objetivo validar se a centralização das informações e a organização dos processos podem facilitar a rotina da instituição.

Entre as principais funcionalidades previstas para o MVP estão:

- Cadastro de clientes.
- Cadastro de informações específicas de clientes materno-infantis.
- Cadastro de informações de clientes de perfuração adulta e enfermagem.
- Cadastro de serviços oferecidos pelo Instituto.
- Realização e visualização de agendamentos.
- Envio automático de lembretes.
- Acompanhamento de contratos e pendências de assinatura.
- Registro e consulta de atendimentos anteriores.
- Visualização de informações importantes no painel inicial.
- Visualização de situações que precisam de atenção.

Geração de resumo inteligente com Inteligência Artificial a partir do histórico da cliente.

A proposta busca reduzir a dependência de ferramentas separadas e tornar a consulta das informações mais rápida e organizada.

3. NECESSIDADES DE DADOS

Para compreender o problema e apoiar o desenvolvimento do sistema, são necessários dados relacionados às clientes, aos atendimentos e ao acompanhamento materno-infantil.

O problema do Instituto Lírios está ligado à falta de centralização das informações. Por esse motivo, o sistema precisará reunir dados que hoje estão distribuídos em diferentes ferramentas. Esses dados serão produzidos e armazenados pelo próprio sistema durante o uso da aplicação.

Entre os principais dados necessários para o funcionamento do sistema estão:

- Dados de identificação e contato das clientes, como nome, telefone, e-mail e data de nascimento.
- Dados relacionados aos serviços utilizados por cada cliente.
- Datas, horários e situação dos agendamentos.
- Dados sobre contratos, assinatura e pendências.
- Registros dos atendimentos realizados.
- Observações feitas durante os atendimentos.
- Informações sobre exames solicitados ou apresentados.
- Informações relacionadas à gestação, como data prevista do parto, idade gestacional e dados do bebê.
- Dados clínicos que possam auxiliar o acompanhamento de gestantes.
- Informações necessárias para gerar alertas, pendências e lembretes.
- Registros históricos e textuais dos atendimentos, que poderão ser utilizados pelo recurso de resumo inteligente com Inteligência Artificial.

A relação entre o problema e as necessidades de dados pode ser compreendida da seguinte forma:

Problema: as informações das clientes estão espalhadas entre WhatsApp, Word, pastas e Google Agenda.

Necessidades de dados: o sistema precisa concentrar dados cadastrais, agendamentos, contratos, pendências, atendimentos, observações e informações relacionadas à gestação.

Dessa forma, os dados permitem que o Instituto Lírios tenha uma visão mais organizada de cada cliente e possa acompanhar melhor sua rotina de atendimentos.

4. PESQUISA E SELEÇÃO DA BASE DE DADOS

4.1 COMPARAÇÃO DAS BASES PESQUISADAS

Antes da escolha da base de dados, foram consideradas outras bases públicas relacionadas à saúde materna e à gestação.

A primeira alternativa foi a Caesarian Section Classification Dataset, disponibilizada pelo UCI Machine Learning Repository. A base possui 80 registros e reúne informações como idade, número de partos, tempo do parto, pressão arterial, problema cardíaco e classificação sobre a realização de cesariana. Apesar de estar relacionada à gestação, possui uma quantidade reduzida de registros e seu foco está especificamente na classificação de cesarianas, não abrangendo de forma tão ampla os fatores de risco materno que interessam ao projeto.

Outra alternativa foi a base Cardiotocography, também disponibilizada pelo UCI Machine Learning Repository. Ela possui 2.126 registros e 21 características, relacionadas principalmente a medições de frequência cardíaca fetal e contrações uterinas, além de classificações realizadas por especialistas. Embora apresente informações relevantes para o acompanhamento fetal, seu foco é mais específico para cardiotocografia e possui uma quantidade maior de variáveis do que o necessário para uma análise inicial simples.

Também foi analisada a Maternal Health Risk, disponibilizada pelo UCI Machine Learning Repository. A base possui 1.013 registros, seis variáveis de entrada e uma variável-alvo, contendo idade, pressão arterial sistólica e diastólica, glicose, temperatura corporal e frequência cardíaca, além da classificação do nível de risco durante a gestação. A documentação da UCI informa que não há valores ausentes. Essa é apenas uma avaliação preliminar da qualidade dos dados; em análises posteriores, poderão ser verificados outros aspectos, como a distribuição das variáveis, possíveis valores discrepantes e a distribuição dos níveis de risco.

4.2 BASE DE DADOS SELECIONADA

A base de dados selecionada para esta etapa é a Maternal Health Risk.

Fonte/origem: UCI Machine Learning Repository, repositório público de conjuntos de dados utilizado em estudos, atividades acadêmicas e projetos de análise de dados. Os dados foram coletados em hospitais, clínicas comunitárias e serviços de saúde materna de áreas rurais de Bangladesh, por meio de um sistema de monitoramento baseado em Internet das Coisas (IoT).

Link oficial: UCI Machine Learning Repository – Maternal Health Risk

Quantidade oficial de registros: 1.014 instâncias ou registros.

Formato da base: arquivo CSV, identificado pela UCI como Maternal Health Risk Data Set.csv.

A base possui seis variáveis de entrada e uma variável-alvo, totalizando sete colunas principais.

Variável	Descrição
Age	Idade da mulher durante a gestação, em anos.
SystolicBP	Valor superior da pressão arterial sistólica, em mmHg.
DiastolicBP	Valor inferior da pressão arterial diastólica, em mmHg.
BS	Nível de glicose no sangue, em mmol/L.
BodyTemp	Temperatura corporal, em graus Fahrenheit.
HeartRate	Frequência cardíaca, em batimentos por minuto.
RiskLevel	Nível de intensidade do risco durante a gestação.

A variável-alvo da base é a coluna RiskLevel. Ela representa o nível de risco relacionado à gestação considerando os valores das demais variáveis disponíveis.

5. DESCRIÇÃO E RELAÇÃO COM O PROBLEMA

A base Maternal Health Risk representa informações relacionadas à saúde de gestantes. Cada registro apresenta dados como idade, pressão arterial, nível de glicose, temperatura corporal, frequência cardíaca e nível de risco durante a gestação.

Esses dados podem contribuir para o projeto do Instituto Lírios porque o sistema possui funcionalidades voltadas ao atendimento materno-infantil. O projeto prevê o cadastro de informações específicas de gestantes, o registro da data prevista do parto, o registro de exames, o histórico de atendimentos e a visualização de informações importantes no painel inicial.

A base pública pode ser utilizada para estudar como dados clínicos e fisiológicos podem estar relacionados a diferentes níveis de risco durante a gestação. Por exemplo, a equipe poderá utilizar a base para explorar os valores de pressão arterial, glicose e frequência cardíaca, verificando como esses dados aparecem nos registros classificados com diferentes níveis de risco.

A utilização dessa base não significa que o sistema do Instituto Lírios fará diagnóstico médico ou substituirá o acompanhamento profissional. A contribuição da base está no apoio às etapas de análise de dados da disciplina, permitindo trabalhar com dados relacionados ao

contexto materno-infantil presente no projeto.

6. JUSTIFICATIVA DA ESCOLHA

A escolha da base Maternal Health Risk foi realizada porque ela possui relação direta com uma das áreas centrais de atuação do Instituto Lírios: o atendimento materno-infantil e o acompanhamento de gestantes.

Outro ponto importante é que a base possui 1.014 registros, uma quantidade adequada para uma análise inicial utilizando a biblioteca pandas. Por possuir um tamanho reduzido e estar em formato CSV, a base pode ser carregada, visualizada, organizada e analisada de forma mais simples durante as atividades da disciplina.

A base também apresenta uma variável-alvo, denominada RiskLevel, que permite desenvolver análises sobre os níveis de risco registrados. Isso pode ser útil em etapas posteriores para explorar os dados e compreender a relação entre as variáveis disponíveis e o nível de risco informado na base.

7. LIMITAÇÕES

A base Maternal Health Risk apresenta limitações importantes quando relacionada ao sistema completo do Instituto Lírios.

A principal limitação é que a base não possui todas as informações necessárias para representar a rotina da instituição. Ela não contém, por exemplo:

- Dados de identificação e contato das clientes.
- Serviços oferecidos pelo Instituto.
- Datas e horários de agendamentos.
- Situação de consultas, cancelamentos ou reagendamentos.
- Controle de contratos e assinaturas.
- Pendências administrativas.
- Registros detalhados de atendimentos.
- Observações feitas pela profissional responsável.
- Histórico completo de cada cliente.
- Informações sobre lembretes enviados.
- Dados específicos sobre documentos anexados.
- Informações administrativas necessárias para o painel inicial do sistema.

Outra limitação é a origem da base, coletada em áreas rurais de Bangladesh. Portanto, os registros não representam diretamente as clientes, os atendimentos ou a realidade local do Instituto Lírios.

A base também não possui informações textuais detalhadas de atendimentos, como relatos,

observações clínicas, orientações, anotações da profissional ou histórico descritivo da cliente.

Essa ausência é especialmente importante para a funcionalidade de resumo inteligente com Inteligência Artificial. Para que o sistema gere resumos organizados das clientes, será necessário utilizar informações históricas e textuais produzidas pelo próprio sistema do Instituto Lírios, como registros de atendimentos, observações, dados de exames, informações da gestação e anotações da profissional responsável.

Portanto, a base pública pode apoiar análises relacionadas à saúde materna e à variável de risco, mas os dados necessários para o funcionamento completo do sistema deverão ser registrados no próprio Instituto Lírios durante a utilização da aplicação.

8. CONCLUSÃO

A realização desta etapa permitiu relacionar o problema identificado no Instituto Lírios às necessidades de dados do projeto e à seleção de uma base pública adequada para as próximas atividades da disciplina de Big Data e Ciência de Dados. Portanto, a escolha da base deve ser entendida como um apoio à análise de dados relacionados à saúde materna, e não como uma base capaz de alimentar todo o sistema. A relação construída nesta TED pode ser apresentada da seguinte forma:

Problema: informações das clientes e atendimentos distribuídas em diferentes ferramentas.

Necessidades de dados: dados organizados sobre clientes, gestação, atendimentos, agendamentos, contratos, pendências e histórico.

Base selecionada: Maternal Health Risk, disponibilizada pela UCI Machine Learning Repository.

Aplicação no projeto: exploração de dados relacionados ao acompanhamento materno e ao nível de risco gestacional, enquanto os dados específicos da rotina do Instituto Lírios serão produzidos pelo próprio sistema.

9. Link do GITHUB

<https://github.com/KelrySilva/Instituto-Lirios-.git>

10. REFERÊNCIAS

AHMED, Marzia. Maternal Health Risk [Dataset]. UCI Machine Learning Repository, 2020.
DOI: 10.24432/C5DP5D. Disponível em:
<https://archive.ics.uci.edu/dataset/863/maternal+health+risk>. Acesso em: 18 set. 2026.

INSTITUTO LÍRIOS. Formulário de levantamento de requisitos para desenvolvimento do sistema Instituto Lírios. Respostas fornecidas pela responsável pela instituição, 2026.